Vous : prédire un tableau de données en utilisant l'entropie de shannon associée à un arbre de décision en python

ChatGPT :

L'entropie de Shannon est utilisée pour mesurer l'incertitude ou l'imprévisibilité d'un ensemble de données. Dans le cadre d'un arbre de décision, l'entropie est utilisée pour déterminer quel attribut divise le mieux les données en fonction de la pureté des classes dans chaque sous-ensemble. L'arbre de décision construit à partir de l'entropie de Shannon cherche à maximiser l'information gagnée à chaque étape du processus de partitionnement.

Voici un exemple de prédiction d'un tableau de données en utilisant l'entropie de Shannon associée à un arbre de décision en Python avec la bibliothèque `sklearn` :

## Étape 1 : Importer les bibliothèques nécessaires

```
import pandas as pd

from sklearn.model_selection import train_test_split

from sklearn.tree import DecisionTreeClassifier

from sklearn.metrics import accuracy_score
```

## Étape 2 : Préparer les données

Imaginons que nous avons un tableau de données simple pour un problème de classification. Nous allons créer un exemple de tableau de données à utiliser dans l'arbre de décision.

```
# Exemple de tableau de données

data = {

    'age': [22, 25, 47, 52, 46, 56, 55, 23, 22, 23],
```

```
    'income': [50000, 60000, 100000, 120000, 100000, 150000, 120000, 45000, 60000, 35000],
    'education': ['Bachelors', 'Masters', 'Bachelors', 'PhD', 'Masters', 'PhD', 'Bachelors', 'Bachelors', 'Masters', 'Highschool'],
    'purchased': [0, 1, 1, 1, 1, 0, 1, 0, 0, 0]  # Variable cible (0 = Non, 1 = Oui)
}

df = pd.DataFrame(data)

# Conversion des variables catégorielles en numériques
df['education'] = df['education'].map({'Highschool': 0, 'Bachelors': 1, 'Masters': 2, 'PhD': 3})

# Séparer les caractéristiques (features) et la cible (target)
X = df[['age', 'income', 'education']]  # Caractéristiques
y = df['purchased']  # Variable cible
```

Étape 3 : Diviser les données en ensembles d'entraînement et de test

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

## Étape 4 : Créer et entraîner l'arbre de décision

Utilisons l'arbre de décision de `sklearn` qui utilise l'entropie de Shannon pour mesurer l'impureté des noeuds et diviser les données.

```
# Créer l'arbre de décision avec l'entropie comme critère de division

clf = DecisionTreeClassifier(criterion='entropy', random_state=42)


# Entraîner l'arbre de décision sur les données d'entraînement

clf.fit(X_train, y_train)
```

## Étape 5 : Prédictions et évaluation

Après avoir formé l'arbre de décision, nous pouvons faire des prédictions sur l'ensemble de test et évaluer sa performance.

```
# Prédire sur l'ensemble de test

y_pred = clf.predict(X_test)


# Calculer l'exactitude du modèle

accuracy = accuracy_score(y_test, y_pred)

print(f"Accuracy: {accuracy * 100:.2f}%")
```

## Étape 6 : Visualiser l'arbre de décision (optionnel)

Si vous souhaitez visualiser l'arbre de décision, vous pouvez utiliser `plot_tree` de `sklearn`.

```
from sklearn.tree import plot_tree
```

```
import matplotlib.pyplot as plt


# Visualiser l'arbre de décision

plt.figure(figsize=(10, 8))

plot_tree(clf, filled=True, feature_names=X.columns, class_names=['No', 'Yes'])

plt.show()
```

## Explication :

- L'argument `criterion='entropy'` indique que l'arbre de décision utilisera l'entropie de Shannon pour évaluer la qualité des divisions à chaque étape.
- Nous avons un jeu de données simple avec trois caractéristiques (âge, revenu et niveau d'éducation) pour prédire si une personne a acheté un produit ou non (variable cible `purchased`).
- Après avoir entraîné l'arbre, nous effectuons des prédictions sur un ensemble de test et mesurons la précision du modèle.

Ce code est un bon point de départ pour utiliser l'entropie de Shannon dans un arbre de décision pour prédire des résultats à partir de données.